

第五章 数据压缩

- **定义** 关于随机变量 X 的信源编码 C 是从 X 的取值空间 $\mathcal{X}$ 到 $\mathcal{D}^*$ 的一个映射，其中 $\mathcal{D}^*$ 表示 D 元字母表 $\mathcal{D}$ 上有限长度的字符串所构成的集合。用 $C(x)$ 表示 x 的码字， $l(x)$ 表示 $C(x)$ 的长度。
- **定义** 设随机变量 X 的概率密度函数为 $p(x)$ ，定义信源编码 $C(x)$ 的期望长度 $L(C)$ 为
$$L(C) = \sum_{x \in \mathcal{X}} p(x) l(x)$$

信源编码的例子

例

$\Pr(X = 1) = 1/2,$	codeword	$C(1) = 0$
$\Pr(X = 2) = 1/4,$	codeword	$C(2) = 10$
$\Pr(X = 3) = 1/8,$	codeword	$C(3) = 110$
$\Pr(X = 4) = 1/8,$	codeword	$C(4) = 111$

$$H(X) = \frac{7}{4} \text{ 比特}$$

$$L(C) = El(X) = \frac{7}{4}$$

信源编码的例子

➤ 例 中文电报的编码方式

- 中文电报的基本编码方法是将每一个汉字或字符用4位十进制数来表示，每一个十进制数再用5位二进制数来表示。
- 例如，“信息论”三个字的电码分别是(0207)，(1873)，(6158)。以“信”为例，首先将它编成4位十进制的码0207，再将它们变换成20位二进制的码：01101 11001 01101 11100，

$$2^{20} = 1048576$$

常用汉字表+次常用汉字表：大约是2500到7000之间
毛泽东所有的著作仅含3136个汉字。孙中山'三民主义'
用了2134个汉字。'骆驼祥子'用了2413个汉字。

信源编码的例子

➤ **例** 摩尔斯电码：使用四个字符的字母表
(点，划，字母间隔和单词间隔)

字符	电码符号	字符	电码符号	字符	电码符号
A	• —	N	— •	1	• — — — —
B	— • • •	O	— — —	2	• • — — —
C	— • — •	P	• — — •	3	• • • — —
D	— • •	Q	— — • —	4	• • • • —
E	•	R	• — •	5	• • • • •
F	• • — •	S	• • •	6	— • • • •
G	— — •	T	—	7	— — • • •
H	• • • •	U	• • —	8	— — — • •
I	• •	V	• • • —	9	— — — — •
J	• — — —	W	• — —	0	— — — — —
K	— • —	X	— • • —	?	• • — — • •
L	• — • •	Y	— • — —	/	— • • — •
M	— —	Z	— — • •	()	— • — — • —
				—	— • • • • —
				•	• — • — • —

编码的类型

- 非奇异（nonsingular）编码：


$$x \neq x' \Rightarrow C(x) \neq C(x')$$

- 扩展（extension）编码：

$$C(x_1x_2 \cdots x_n) = C(x_1)C(x_2) \cdots C(x_n)$$

- 唯一可译（uniquely decodable）编码：扩展编码是非奇异的
- 前缀码（prefix code）或即时码（instantaneous code）：码中无任何码字是其他码字的前缀。

编码的类型



Kraft不等式

- 信源编码的目标：构造期望长度最小的即时码
- **Kraft不等式**：对于D元字母表上的即时码，码字长度 $l_1, l_2, \dots, l_m$ 必须满足不等式

$$\sum_i D^{-l_i} \leq 1$$


反之，若给定满足以上不等式的一组码字长度，则存在一个相应的即时码，其码字长度就是给定的长度。

- 推广的**Kraft不等式**：
$$\sum_{i=1}^{\infty} D^{-l_i} \leq 1$$


码树

- 对于给定码字的全体集合，可以用码树来描述。
 - 对于 r 进制的码树，如下页图所示，其中图(a)为二元码树，图(b)为三元码树。在码树中R点是树根，从树根伸出个树枝，构成 r 元码树。树枝的尽头是节点，一般中间节点会伸出树枝，不伸出树枝的节点为终端节点，编码时应尽量在终端节点安排码字。
-

码树




(a) 二元码树



(b) 三元码树

Kraft不等式的证明



Kraft不等式的充分必要性

- Kraft不等式是即时码**存在**的充要条件，其必要性表现在如果码是即时码，则必定满足Kraft不等式；充分性表现在如果满足Kraft不等式，则这种码长的即时码一定**存在**，但并不表示所有满足Kraft不等式的码一定是即时码。
 - 因此， Kraft不等式是即时码**存在**的充要条件，而不是即时码的充要条件。
-

惟一可译码的Kraft不等式

- 对于D元字母表上的惟一可译码，码字长度 $l_1, l_2, \dots, l_m$ 必须满足Kraft不等式

$$\sum_i D^{-l_i} \leq 1$$

反之，若给定满足以上不等式的一组码字长度，则可以构造出具有同样码字长度的惟一可译码。

最优码

➤ 最优化问题：在所有满足 $\sum_{i=1}^{\infty} D^{-l_i} \leq 1$ 整数 $l_1, l_2, \dots, l_m$ 中，最小化 $L = \sum p_i l_i$

- ✓ 取消 l_i 必须是整数的限制
- ✓ 约束条件中的等号成立
- ✓ 拉格朗日乘子法（Lagrange Multiplier）

➤ **定理** 随机变量 X 的任一 D 元即时码的期望长度

$$L \geq H_D(X)$$

当且仅当 $D^{-l_i} = p_i$ ，等号成立

寻找最优码

-  **定义** **D进制的 (D-adic)** 概率分布：每一个概率值均等于 D^{-n}
- 寻找最优码的方法
 - ✓ 找到与X的分布最接近的D进制分布（在相对熵意义下）
 - ✓ 该D进制概率分布可提供一组码字长度
 - ✓ 构造码字

最优码长的界

- **定理** 设 $l_1^*, l_2^*, \dots, l_m^*$ 是关于信源分布 $\mathbf{p}$ 和一个 D 元字母表的一组最优码长, L^* 为最优码的相应期望长度, 则

$$H_D(X) \leq L^* < H_D(X) + 1$$

- 多字符分组编码:

$$L_n = \frac{1}{n} \sum p(x_1, x_2, \dots, x_n) l(x_1, x_2, \dots, x_n) = \frac{1}{n} E l(X_1, X_2, \dots, X_n)$$

$$\frac{H_D(X_1, X_2, \dots, X_n)}{n} \leq L_n < \frac{H_D(X_1, X_2, \dots, X_n)}{n} + \frac{1}{n}$$

$$X_1, X_2, \dots, X_n \text{ 独立同分布: } H_D(X) \leq L_n < H_D(X) + \frac{1}{n}$$

香农第一定理


➤ **定理** 香农第一定理（可变长无失真信源编码定理）

设 $X_1, X_2, \dots, X_n$ 为离散无记忆信源 X 的 n 次扩展，对 n 次扩展信源进行编码，平均每字符期望码长为 L_n ，则对任意给定的 $\varepsilon > 0$ ，当 n 足够大时，总可以找到一种无失真惟一可译编码，满足

$$H_D(X) \leq L_n < H_D(X) + \varepsilon$$

反之，若 $L_n < H_D(X)$ ，则信源编码不可能无失真。

构造最优即时码



$$l(x) = \left\lceil \log \frac{1}{p(x)} \right\rceil$$

不正确分布引起的误差

➤ **定理** 码字长度分配 $l(x) = \left\lceil \log \frac{1}{q(x)} \right\rceil$ 关于 $p(x)$ 的期望码长满足

$$H(p) + D(p\|q) \leq E_p l(X) < H(p) + D(p\|q) + 1$$

例

$$\begin{aligned} \left[\begin{array}{c} X \\ p(X) \end{array} \right] &= \left\{ \begin{array}{cccc} 1 & 2 & 3 & 4 \\ \frac{1}{2} & \frac{1}{4} & \frac{1}{8} & \frac{1}{8} \end{array} \right\} & L_p(X) = 1.75 \text{ 比特}; L_q(X) = 2 \text{ 比特} \\ \left[\begin{array}{c} X \\ q(Y) \end{array} \right] &= \left\{ \begin{array}{cccc} 1 & 2 & 3 & 4 \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} \end{array} \right\} & D(p\|q) = \sum p(x) \log \frac{p(x)}{q(x)} = 0.25 \text{ 比特} \end{aligned}$$

赫夫曼码

例

$$D = 2$$

Codeword length	Codeword	X	Probability
2	01	1	0.25
2	10	2	0.25
2	11	3	0.2
3	000	4	0.15
3	001	5	0.15

$$L = 2.3 \text{ 比特}$$

赫夫曼码

例

$D = 3$

码字	X	概率			
12	1	0.25	0.3	0.7	1
11	2	0.25	0.25	0.3	
10	3	0.2	0.25		
02	4	0.1	0.2		
01	5	0.1			
00	6	0.1			

$L = 2$ 铁特 (ternary digit)

赫夫曼码

例

$D = 3$

$$|\mathcal{X}| = 1 + k(D - 1)$$

码字	x	概率			
12	1	0.25	0.3	0.7	1
11	2	0.25	0.25	0.3	
10	3	0.2	0.25		
02	4	0.1	0.2		
01	5	0.1			
00	6	0.1			

$L = 2$ 铁特 (ternary digit)

赫夫曼码

例

$$D = 3$$

$$|\mathcal{X}| = 1 + k(D - 1)$$

Codeword	X	Probability
1	1	0.25
2	2	0.25
01	3	0.2
02	4	0.1
000	5	0.1
001	6	0.1
002	Dummy	0.0

$$L = 1.7 \text{ 比特 (ternary digit)}$$

赫夫曼码和“20 questions”


- **20 questions:** 一个人在心里想好一个东西，其他人要争取在20个问题以内揭开谜底，但出题者只能回答Yes或No
- 假设目标的概率分布已知，如何找到最有效的问题序列？
- 0表示Yes，1表示No，最优问题序列和二元赫夫曼编码等价：“ $X \in A$ 吗？”
- 最有期望问题数

$$H(X) \leq EQ < H(X) + 1$$

赫夫曼码的讨论

- 加权码字的赫夫曼编码：赫夫曼算法最小化的是码长加权和 $\sum p_i l_i$

<i>X</i>	Codeword	Weights			
1	00	5	8	10	18
2	01	5	5	8	
3	10	4	5		
4	11	4			



赫夫曼码的讨论

$$H_D(X) \leq L^* < H_D(X) + 1$$

- 赫夫曼编码和香农码（码字长度 $l(x) = \left\lceil \log \frac{1}{p(x)} \right\rceil$ ）
- ✓ 从平均意义上讲，赫夫曼编码具有更短的期望长度，但两者的差别不超过1比特
 - ✓ 对于单个字符来说，香农码可能具有比赫夫曼码更短的码字长度

码字长度	码字	x	概率
1	1	1	1/3
2	01	2	1/3
3	001	3	1/4
3	000	4	1/12


$$L_{Huffman} = 2 \text{ 比特}$$

$$L_{Shannon} = 2.17 \text{ 比特}$$


赫夫曼码的最优性

- **定理** 对任意一个分布，必然存在满足如下性质的一个最优即时码：
 1. 其长度序列与按概率分布排列的次序相反
 2. 最长的两个码字具有相同长度
 3. 最长的两个码字仅在最后一位上有所差别，且对应与两个最小可能发生的字符
- 满足以上定理得最优码称为**典则码**
- **定理** 赫夫曼码是最优的，它提供了最短的期望码长
$$L(C^*) \leq L(C')$$


Country	Year	Value
Algeria	2010	0.00
Algeria	2011	0.00
Algeria	2012	0.00
Algeria	2013	0.00
Algeria	2014	0.00
Algeria	2015	0.00
Algeria	2016	0.00
Algeria	2017	0.00
Algeria	2018	0.00
Algeria	2019	0.00
Algeria	2020	0.00
Algeria	2021	0.00
Algeria	2022	0.00
Algeria	2023	0.00
Algeria	2024	0.00
Algeria	2025	0.00
Algeria	2026	0.00
Algeria	2027	0.00
Algeria	2028	0.00
Algeria	2029	0.00
Algeria	2030	0.00
Algeria	2031	0.00
Algeria	2032	0.00
Algeria	2033	0.00
Algeria	2034	0.00
Algeria	2035	0.00
Algeria	2036	0.00
Algeria	2037	0.00
Algeria	2038	0.00
Algeria	2039	0.00
Algeria	2040	0.00
Algeria	2041	0.00
Algeria	2042	0.00
Algeria	2043	0.00
Algeria	2044	0.00
Algeria	2045	0.00
Algeria	2046	0.00
Algeria	2047	0.00
Algeria	2048	0.00
Algeria	2049	0.00
Algeria	2050	0.00
Algeria	2051	0.00
Algeria	2052	0.00
Algeria	2053	0.00
Algeria	2054	0.00
Algeria	2055	0.00
Algeria	2056	0.00
Algeria	2057	0.00
Algeria	2058	0.00
Algeria	2059	0.00
Algeria	2060	0.00
Algeria	2061	0.00
Algeria	2062	0.00
Algeria	2063	0.00
Algeria	2064	0.00
Algeria	2065	0.00
Algeria	2066	0.00
Algeria	2067	0.00
Algeria	2068	0.00
Algeria	2069	0.00
Algeria	2070	0.00
Algeria	2071	0.00
Algeria	2072	0.00
Algeria	2073	0.00
Algeria	2074	0.00
Algeria	2075	0.00
Algeria	2076	0.00
Algeria	2077	0.00
Algeria	2078	0.00
Algeria	2079	0.00
Algeria	2080	0.00
Algeria	2081	0.00
Algeria	2082	0.00
Algeria	2083	0.00
Algeria	2084	0.00
Algeria	2085	0.00
Algeria	2086	0.00
Algeria	2087	0.00
Algeria	2088	0.00
Algeria	2089	0.00
Algeria	2090	0.00
Algeria	2091	0.00
Algeria	2092	0.00
Algeria	2093	0.00
Algeria	2094	0.00
Algeria	2095	0.00
Algeria	2096	0.00
Algeria	2097	0.00
Algeria	2098	0.00
Algeria	2099	0.00
Algeria	2100	0.00
Algeria	2101	0.00
Algeria	2102	0.00
Algeria	2103	0.00
Algeria	2104	0.00
Algeria	2105	0.00
Algeria	2106	0.00
Algeria	2107	0.00
Algeria	2108	0.00
Algeria	2109	0.00
Algeria	2110	0.00
Algeria	2111	0.00
Algeria	2112	0.00
Algeria	2113	0.00
Algeria	2114	0.00
Algeria	2115	0.00
Algeria	2116	0.00
Algeria	2117	0.00
Algeria	2118	0.00
Algeria	2119	0.00
Algeria	2120	0.00
Algeria	2121	0.00
Algeria	2122	




(a)



(b)




(c)




(d)


赫夫曼码的最优性



(a)



(b)



(c)

	$C_{m-1}^*(\mathbf{p}')$		$C_m(\mathbf{p})$	
p_1	w'_1	l'_1	$w_1 = w'_1$	$l_1 = l'_1$
p_2	w'_2	l'_2	$w_2 = w'_2$	$l_2 = l'_2$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
p_{m-2}	w'_{m-2}	l'_{m-2}	$w_{m-2} = w'_{m-2}$	$l_{m-2} = l'_{m-2}$
$p_{m-1} + p_m$	w'_{m-1}	l'_{m-1}	$w_{m-1} = w'_{m-1}0$	$l_{m-1} = l'_{m-1} + 1$
			$w_m = w'_{m-1}1$	$l_m = l'_{m-1} + 1$

Shannon-Fano-Elias编码


- 累计分布函数：假定取 $\mathcal{X} = \{1, 2, \dots, m\}$ ，并对所有 x ，有 $p(x) > 0$ 。定义累计分布函数

$$F(x) = \sum_{a \leq x} p(a)$$

- 修正的累计分布函数

$$\bar{F}(x) = \sum_{a < x} p(a) + \frac{1}{2}p(x)$$

Shannon-Fano-Elias编码



Shannon-Fano-Elias编码

- $\overline{F}(x)$ 唯一确定 x ，可作为 x 的编码
- 一般情况下， $\overline{F}(x)$ 需用无限多比特表示
- 取 $\overline{F}(x)$ 的前 $l(x)$ 位作为 x 的编码： $\lfloor \overline{F}(x) \rfloor_{l(x)}$

$$l(x) = \left\lceil \log \frac{1}{p(x)} \right\rceil + 1$$

- 此编码是前缀码
- 编码的期望长度：

$$L < H(X) + 2$$

Shannon-Fano-Elias编码的例子

x	$p(x)$	$F(x)$	$\bar{F}(x)$	$\bar{F}(x)$ in binary	$l(x) = \lceil \log \frac{1}{p(x)} \rceil + 1$	Codeword
1	0.25	0.25	0.125	0.001	3	001
2	0.5	0.75	0.5	0.10	2	10
3	0.125	0.875	0.8125	0.1101	4	1101
4	0.125	1.0	0.9375	0.1111	4	1111

$$L = 2.75 \text{ 比特}, \quad H(X) = 1.75 \text{ 比特}$$

x	$p(x)$	$F(x)$	$\bar{F}(x)$	$\bar{F}(x)$ in binary	$l(x) = \left\lceil \log \frac{1}{p(x)} \right\rceil + 1$	Codeword
1	0.25	0.25	0.125	0.001	3	001
2	0.25	0.5	0.375	0.011	3	011
3	0.2	0.7	0.6	0.10011	4	1001
4	0.15	0.85	0.775	0.1100011	4	1100
5	0.15	1.0	0.925	0.1110110	4	1110

博弈和信息论

➤ 赛马： m 匹马，第 i 匹马获胜概率 p_i ，机会收益 o_i 比 1

➤ 所有资金分散下注：第 i 匹马下注比例 b_i

➤ 反复下注， S_n 为第 n 场比赛结束后资产

$$S_n = \prod_{i=1}^n S(X_i) \quad S(X) = b(X)o(X)$$

➤ **定理** 假设赛马的结果 $X_1, X_2 \dots X_n$ 服从 $p(x)$ 的独立同分布序列，则策略 b 之下的相对收益将指数增长

$$S_n \doteq 2^{nW(b,p)} \quad W(b,p) = E(\log S(X)) = \sum_{k=1}^m p_k \log b_k o_k$$

博弈和信息论

- **定理**（按比例下注是对数最优化的）最优化倍率的公式为

$$W^*(\mathbf{p}) = \sum p_i \log o_i - H(\mathbf{p})$$

并且按比例下注 $\mathbf{b}^* = \mathbf{p}$ 的下注策略可以达到该值

- 分布未知，公平机会收益倍率 $\sum 1/o_i = 1$

$$W(\mathbf{b}, \mathbf{p}) = \sum p_i \log b_i o_i$$

$$= \sum p_i \log \left(\frac{b_i p_i}{p_i r_i} \right)$$

$$= D(\mathbf{p} \parallel \mathbf{r}) - D(\mathbf{p} \parallel \mathbf{b})$$

$$r_i = 1/o_i$$

博弈和信息论

- **定理**（守恒定理）对于均匀的公平机会收益倍率（ m 兑1）

$$W^*(\mathbf{p}) + H(\mathbf{p}) = \log m$$

- 允许有选择的保留一部分现金（比例为 b_0 ）
- 服从某种分布的公平机会收益倍率：按比例下注最优
 - 超公平机会收益倍率 $\sum \frac{1}{o_i} < 1$ ：收益优于公平机会，一般全额资金投入，按比例下注最优
 - 次公平机会收益倍率 $\sum \frac{1}{o_i} > 1$ ：现实情况，按比例下注非最优

博弈和边信息

➤ 已知边信息Y: $p(x, y)$

➤ 下注策略: $b(x|y)$

$$W^*(X) = \max_{b(x)} \sum_x p(x) \log b(x) o(x)$$

$$W^*(X|Y) = \max_{b(x|y)} \sum_{x,y} p(x,y) \log b(x|y) o(x)$$

➤ 倍率增量: $\Delta W = W^*(X|Y) - W^*(X)$

➤ **定理** 由于获得某场赛马X的边信息Y而引起的倍率增量为

$$\Delta W = I(X; Y)$$