

第8章 微分熵

➤ **定义** 设 X 是一个随机变量，其累积分布函数为 $F(x) = \Pr(X \leq x)$ 。如果 $F(x)$ 是连续的，则称该随机变量是连续的。当 $F(x)$ 的导数存在时，令 $f(x) = F'(x)$ 。若 $\int_{-\infty}^{\infty} f(x) dx = 1$ ，则称 $f(x)$ 是 X 的概率密度函数。另外，使 $f(x) > 0$ 的所有 x 构成的集合称为 X 的支撑集。

➤ **定义** 一个以 $f(x)$ 为密度函数的连续随机变量 X 的微分熵（differential entropy）定义为

$$h(X) = - \int_S f(x) \log f(x) dx$$

第8章 微分熵

➤ **定义** 设 X 是一个随机变量，其累积分布函数为 $F(x) = \Pr(X \leq x)$ 。如果 $F(x)$ 是连续的，则称该随机变量是连续的。当 $F(x)$ 的导数存在时，令 $f(x) = F'(x)$ 。若 $\int_{-\infty}^{\infty} f(x) dx = 1$ ，则称 $f(x)$ 是 X 的概率密度函数。另外，使 $f(x) > 0$ 的所有 x 构成的集合称为 X 的支撑集。

➤ **定义** 一个以 $f(x)$ 为密度函数的连续随机变量 X 的微分熵（**differential entropy**）定义为

$$h(X) = - \int_S f(x) \log f(x) dx$$
$$H(X) = - \sum_{x \in \mathcal{X}} p(x) \log p(x)$$

微分熵的例子

➤ 例 $[0, a]$ 上的均匀分布:

$$h(X) = - \int_0^a \frac{1}{a} \log \frac{1}{a} dx = \log a \text{ 比特}$$

✓ $a < 1$ 时, $h(X) < 0$

➤ 例 正态分布 $X \sim \mathcal{N}(0, \sigma^2) = \phi(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{x^2}{2\sigma^2}}$:

$$h(\phi) = \frac{1}{2} \log 2\pi e \sigma^2 \text{ 比特}$$

连续随机变量的AEP

- AEP: 对于一个独立同分布的随机变量序列来说,

$$p(X_1, X_2, \dots, X_n) \rightarrow 2^{-nH(X)}$$

- **定理** 设 $X_1, X_2, \dots, X_n$ 是一个服从密度函数 $f(x)$ 的独立同分布的随机变量序列, 则

$$-\frac{1}{n} \log f(X_1, X_2, \dots, X_n) \rightarrow E[-\log f(X)] = h(X) \text{ 依概率}$$

- **定义** 对 $\epsilon > 0$ 及任意的 n , 定义 $f(x)$ 的典型集 $A_\epsilon^{(n)}$ 如下

$$A_\epsilon^{(n)} = \left\{ (x_1, x_2, \dots, x_n) \in S^n : \left| -\frac{1}{n} \log f(x_1, x_2, \dots, x_n) - h(X) \right| \leq \epsilon \right\}$$

其中

$$f(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i)$$

连续随机变量的典型集性质


➤ **定义** 集合的体积 $\text{Vol}(A)$ 定义为

$$\text{Vol}(A) = \int_A dx_1 dx_2 \cdots dx_n$$

➤ **定理** 连续随机变量的典型集有如下的性质：

1. 对于充分大的 n , $\Pr(A_\epsilon^{(n)}) > 1 - \epsilon$
2. 对于所有的 n , $\text{Vol}(A_\epsilon^{(n)}) \leq 2^{n(h(X)+\epsilon)}$
3. 对于充分大的 n , $\text{Vol}(A_\epsilon^{(n)}) \geq (1 - \epsilon)2^{n(h(X)-\epsilon)}$

微分熵和离散熵的区别




➤ **定理** 如果随机变量 X 的密度函数 $f(x)$ 是黎曼可积的，那么

$$H(X^\Delta) + \log \Delta \rightarrow h(f) = h(X), \quad \text{当 } \Delta \rightarrow 0$$

微分熵和离散熵的区别

- $H(X) = h(X) - \lim_{\Delta \rightarrow 0} \log \Delta$
 $= h(X) + \{\text{无穷大常数}\}$
- $H(X)$ 是离散意义的熵，是信息熵，无限大
- $h(X)$ 是连续意义的熵，是微分熵
- 微分熵 $h(X)$ 不代表信源 X 的平均不确定度，也不代表 X 每取一个数值所提供的平均信息量，不含有信息度量的内涵

微分熵和离散熵的区别



- 连续随机变量 X 经过精确到小数点后 n 比特位的量化处理后，熵的值大约是 $h(X) + n$
- 一般情况下，在精确到 n 位的意义下， $h(X) + n$ 是为了描述 X 所需的平均比特数。
- 一个离散随机变量的微分熵可以看作是 $-\infty$

联合微分熵与条件微分熵

- **定义** 联合密度函数为 $f(x_1, x_2, \dots, x_n)$ 的一组随机变量 $X_1, X_2, \dots, X_n$ 的联合微分熵定义为

$$h(X_1, X_2, \dots, X_n) = - \int f(x^n) \log f(x^n) dx^n$$

- **定义** 如果 X, Y 的联合密度函数为 $f(x, y)$, 定义条件微分熵为

$$h(X|Y) = - \int f(x, y) \log f(x|y) dx dy$$

联合微分熵与条件微分熵

- **定义** 联合密度函数为 $f(x_1, x_2, \dots, x_n)$ 的一组随机变量 $X_1, X_2, \dots, X_n$ 的联合微分熵定义为

$$h(X_1, X_2, \dots, X_n) = - \int f(x^n) \log f(x^n) dx^n$$

- **定义** 如果 X, Y 的联合密度函数为 $f(x, y)$, 定义条件微分熵为

$$h(X|Y) = - \int f(x, y) \log f(x|y) dx dy$$

$$h(X|Y) = h(X, Y) - h(Y)$$

多元正态分布的熵

$$h(\phi) = \frac{1}{2} \log 2\pi e \sigma^2 \text{ 比特}$$

➤ **定理** 设 $X_1, X_2, \dots, X_n$ 服从均值为 μ , 协方差矩阵为 K 的多元正态分布 $\mathcal{N}_n(\mu, K)$, 则

$$h(X_1, X_2, \dots, X_n) = h(\mathcal{N}_n(\mu, K)) = \frac{1}{2} \log(2\pi e)^n |K| \text{ 比特}$$

其中 $|K|$ 表示 K 的行列式。

相对熵和互信息

$$h(X) = - \int_S f(x) \log f(x) dx$$

➤ **定义** 两个密度函数**f**和**g**之间的相对熵:

$$D(f\|g) = \int f \log \frac{f}{g}$$

$$D(p\|q) = \sum_{x \in \mathcal{X}} p(x) \log \frac{p(x)}{q(x)}$$

➤ **定义** 联合密度函数为**f(x,y)**的两个随机变量间的互信息:


$$I(X;Y) = \int f(x,y) \log \frac{f(x,y)}{f(x)f(y)}$$

$$I(X;Y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x,y) \log \frac{p(x,y)}{p(x)p(y)}$$

$$I(X;Y) = h(X) - h(X|Y) = h(Y) - h(Y|X) = h(X) + h(Y) - h(X,Y)$$

$$I(X;Y) = D(f(x,y)\|f(x)f(y))$$

互信息的例子



$$(X, Y) \sim \mathcal{N}(0, K)$$

$$K = \begin{pmatrix} \sigma^2 & \rho\sigma^2 \\ \rho\sigma^2 & \sigma^2 \end{pmatrix}$$

$$h(X) = h(Y) = \frac{1}{2} \log(2\pi e) \sigma^2$$

$$h(X, Y) = \frac{1}{2} \log(2\pi e)^2 |K| = \frac{1}{2} \log(2\pi e)^2 \sigma^4 (1 - \rho^2)$$

$$I(X; Y) = h(X) + h(Y) - h(X, Y) = -\frac{1}{2} \log(1 - \rho^2)$$

微分熵、相对熵和互信息的性质

- $D(f\|g) \geq 0$ ，当且仅当 $f=g$ 时，等号成立
- $I(X;Y) \geq 0$ ，当且仅当 X 与 Y 相互独立时等号成立
- $h(X|Y) \leq h(X)$ ，当且仅当 X 与 Y 相互独立时等号成立
- $h(X_1, X_2, \dots, X_n) = \sum_{i=1}^n h(X_i|X_1, X_2, \dots, X_{i-1})$
- $h(X_1, X_2, \dots, X_n) \leq \sum h(X_i)$ ，当且仅当所有随机变量相互独立时等号成立
- 平移变换不会改变微分熵： $h(X + c) = h(X)$
- $h(aX) = h(X) + \log |a|$ $h(A\mathbf{X}) = h(\mathbf{X}) + \log |\det A|$

$$-\int_{-\infty}^{\infty} q(x) \ln p(x) dx = -\int_{-\infty}^{\infty} p(x) \ln p(x) dx$$

微分熵、相对熵和互信息的性质

- 设n维随机变量X均值为0，协方差矩阵 $K = E\{XX^t\}$ 则 $h(X) \leq \frac{1}{2} \log(2\pi e)^n |K|$ ，当且仅当 $X \sim \mathcal{N}(0, K)$ 时等号成立。
- 对任意随机变量X及其估计，
$$E(X - \hat{X})^2 \geq \frac{1}{2\pi e} e^{2h(X)}$$

X为正态分布且估计为其均值时，等号成立

- 微分熵不存在绝对的最大熵。连续随机变量的最大熵与随机变量的限制条件有关。在不同的限制条件下，有不同的最大微分熵。
- 当已知边信息Y时，

$$E(X - \hat{X}(Y))^2 \geq \frac{1}{2\pi e} e^{2h(X|Y)}$$