



《数学实验》第11讲

主要内容:

数据拟合

数据拟合之一——人口增长问题拟合

数据拟合之一——思考


实践1：新冠肺炎人数预测

引例:



行星	轨道半 长轴 (10^{10} 米)	周期 (年)
水星	5.79	0.241
金星	10.8	0.615
地球	15.0	1
火星	22.8	1.88
木星	77.8	11.9
土星	143	29.5
天王星	287	84
海王星	450	165
冥王星	590	248

```
>> x=[0.241 0.615 1 1.88 11.9 29.5 84 165 248];  
>> y=[5.79 10.8 15.0 22.8 77.8 143 287 450 590];  
>> plot(x,y,'o')
```



开普勒大胆猜测：绕以太阳为焦点的椭圆轨道运行的所有行星，其各自椭圆轨道半长轴的立方与周期的平方之比是一个常量。即




$$T^2 = ca^3$$

$$T^2 = ca^3$$


行 星	半长轴 (a)	周期 (T)	c
海王星	450	165	298
天王星	287	84	299

Q: 如何求 c ?

❖ 已知一组数据, 即平面上离散点 (x_i, y_i) , $i = 1, \dots, n$



➤ 寻求一条直线 $y=ax+b$ 使直线在某种规则下与所有数据点最为接近, 或称直线与离散数据拟合地最好。



离散点 (x_i, y_i) 与直线 $y=ax+b$ 的距离平方之和最小。即

$$S = (ax_1 + b - y_1)^2 + \cdots + (ax_n + b - y_n)^2$$

对 S 求 a 和 b 的偏导数，并令其为 0，得到如下方程组

$$(ax_1 + b - y_1) + \cdots + (ax_n + b - y_n) = 0$$

$$x_1(ax_1 + b - y_1) + \cdots + x_n(ax_n + b - y_n) = 0$$

整理得到：

$$\begin{pmatrix} 1 + \cdots + 1 & x_1 + \cdots + x_n \\ x_1 + \cdots + x_n & x_1^2 + \cdots + x_n^2 \end{pmatrix} \begin{pmatrix} b \\ a \end{pmatrix} = \begin{pmatrix} y_1 + \cdots + y_n \\ x_1 y_1 + \cdots + x_n y_n \end{pmatrix}$$

主要函数:

1. 多项式拟合函数: `polyfit()`

调用格式: `p=polyfit(x,y,n)`

输入: `x, y`—数据点, `n`—多项式阶数,

输出: `p` 为幂次从高到低的多项式系数向量`p`


2. 多项式求值函数: `polyval()`

调用格式: `y=polyval(p,x)`

说明: `y=polyval(p,x)`为返回对应自变量`x`在给定系数`p`的多项式的值。

举例:

```
>> x = [1 2 4 5];  
>> y = [1 2 2 3];  
>> plot(x,y,'o')  
>> p=polyfit(x,y,1)  
>> xnew=linspace(min(x),max(x));  
>> ynew=polyval(p,xnew);  
>> hold on, plot(xnew,ynew, 'r')
```



一、数据拟合问题简介

数据拟合：从一大堆看上去杂乱无章的数据中找出规律性来，即设法构造一条曲线（拟合曲线）反映所给数据点总的趋势，以消除其局部波动。

常用拟合方法：多项式拟合

存在问题：并不是所有问题都可以用多项式作拟合，比如人口增长问题。

二、人口增长问题的数据拟合方法

问题：已知1996-2004年全国人口总数如下表，试根据表中数据预测2020年全国人口总数。（单位：亿）

年	1996	1997	1998	1999	2000
人口	12.2389	12.3626	12.4761	12.5876	12.6743

2001	2002	2003	2004
12.7627	12.8453	12.9227	13.0000

分析：据人口增长的统计资料 and 人口理论数学模型知，当**人口总数** N 不是很大时，在不太长的**时期** t 内，人口增长接近于指数增长。

故采用指数函数对数据进行拟合

$$N = e^{a+bt}$$

为了计算方便，将上式两边同时取对数，得

$$\ln N = a + bt$$

令：

$$y = \ln(N) \quad N_i \rightarrow y_i$$

变换后的拟合函数为

$$y(t) = a + bt$$

(t_i, y_i)

由人口数据表对人口取对数，计算得：

t	1996	1997	1998	1999	2000	2001	2002	2003	2004
y	2.5046	2.5147	2.5238	2.5327	2.5396	2.5465	2.5530	2.5590	2.5649

N_i

利用拟合函数polyfit对该组数据进行拟合，并计算当t=2020时的函数值：

```
clear,clc
```

```
t=[1996 1997 1998 1999 2000 2001 2002 2003 2004];
```

```
y=[2.5046 2.5147 2.5238 2.5327 2.5396 2.5465 2.5530 2.5590 2.5649];
```

```
p=polyfit(t,y,1)
```

```
Z=polyval(p,2020)
```

程序运行结果：

$p = 0.0074 \quad -12.3390$

$Z = 2.6864$

即：

$$a = -12.3390, \quad b = 0.0074$$

代入拟合函数得：

$$N = e^{-12.3390+0.0074t}$$

当 $t=2020$ 时， $N=14.6787$ ：

即到2020年时，全国总人口数将达到14.6787亿

这一数据虽然不十分准确，但是基本反映了人口变化趋势。

数据拟合——应用

- 1) 机器学习;
- 2) 数据预测;
- 3) 其他预测问题

机器学习:

$(x_i, y_i), i=1, \dots, m$
~~Input label~~

$$y = ax + b$$

$$ax_1 + b = y_1$$

$$ax_m + b = y_m$$

③

$\min_{a, b}$

a^*, b^*

$$y = a^*x + b^*$$

训练数据

验证数据

给定: x

$$y_1 = a^*x_1 + b^*$$

预测值

实践1：新冠肺炎人数预测（20分钟）



新冠肺炎中国确诊人数/治愈人数预测及思考：

1)数据获取（非常重要） <https://wh.opensource-service.cn/#/>

a)请进入如上网站，手动收集随日期(存入t)增加的肺炎确诊人数(存入x)/治愈人数(存入y)。**搜集日期**：从1月28日开始至2月28日；**间隔**：三天记录一次

举例：搜集1.28 – 2.06日数据，记录的 $t = [1, 4, 7, 10]$ ； $x = [4630, 9811, 17340, 28138]$ ； $y = [73, 214, 527, 1373]$

b)请选用合适的多项式拟合你所收集的数据规律。

c)根据上面的拟合结果，请预测1月30日、2月15日、2月21日、3月3日的确诊人数/治愈人数为多少？

d)思考：i) 你的预测结果和实际数量相差大么？
ii) 如果相差大，问题在哪里/如何改进？

数据拟合

数据拟合之——人口增长问题拟合

数据拟合之——思考

实践1：新冠肺炎人数预测