



西安交通大学
XI'AN JIAOTONG UNIVERSITY

IAIR Est.
1986

Institute of
Artificial Intelligence
and Robotics



人工智能学院
College of Artificial Intelligence, XJTU

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

《高级机器学习》第五章

稀疏学习与压缩感知

Sparse learning & compressed sensing

魏平

西安交通大学人工智能学院
人工智能与机器人研究所

数字传感器

- ❑ 在数字化时代，所有的数字信号采集都必须有相应的数字化的软硬件支撑。随着人们对于图像、视频等多媒体内容的需求和要求越来越高，对应的硬件设备如照相机、摄像机等信号采集的设备压力也越来越大
- ❑ 比如，相片的分辨率越来越高，这就需要在照相机中内置越来越多的传感器，以采集质量更高的图像信号。此外还有其他一些目前传统信号采集方式无法有效满足的需求，不可见光如X射线、伽马射线等信号采集、高速视频采集等
- ❑ 在这样一个对信号采集越来越苛刻的需求下，有没有一种**更有效的采集、传输、存储以及处理的方法**




传统数字信号采集

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

- 传统的数字信号采样基于香农采样定理，又称奈奎斯特采样定律：为了不失真地恢复模拟信号，采样频率应该不小于模拟信号频谱中最高频率的2倍
- 下图分别为在时域和空域上的数字化



time




space

传统数字信号采集

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

- 基于香农采样定理，目前传统图像信号采集传输的采样过程：
- 方法一：按照Nyquist采样率进行均匀采样($2 \times$ 傅里叶带宽)，得到可以无失真恢复模拟信号的数字信号




- 上述方法得到的数字信号的数据量比较大，信号存在冗余，不利于存储和传输，数字信号本来存在很多冗余，可以对其进一步的压缩

传统数字信号采集

西安交通大学人工智能学院魏平编写。课程资料，请勿外传



□ 方法二：通过各种编码方法对数据进行有效的压缩



- 相机的传感器通过将模拟信号（光）转换为数字信号之后又通过压缩编码算法将 N 像素的图像信号转化为 K 个系数表示的数据，而 $K \ll N$ ；获得了 N 个采样值，却最后又通过复杂的编码算法将之压缩成 K 个数值，何故如此？
- 这个疑问催生了**压缩感知的概念**

压缩感知(Compressed sensing)

- 压缩感知 (compressed sensing) , 也称为压缩采样(compressive sampling), 稀疏采样(sparse sampling), 它关注信号的稀疏特性, 在远小于Nyquist采样率的条件下, 用随机采样获取信号的离散样本, 通过非线性算法重建信号



Terence Chi-Shen Tao

陶哲轩

压缩感知

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

- 假定有长度为 m 的离散数字信号 x ，我们以远小于奈奎斯特采样定理要求的采样率进行采样，得到长度为 n 的采样后信号 y ， $n \ll m$ ，

$$y = \Phi x$$

其中 $\Phi \in \mathbb{R}^{n \times m}$ 是对信号 x 的测量矩阵，它确定了以什么频率进行采样以及如何将采样样本组成采样后的信号

- 投影矩阵 Φ 并不是满秩的，因此公式 $y = \Phi x$ 的左边两边并不是等价的过程：已知 x 和测量矩阵 Φ ，要得到测量值 y 很容易；但若将测量值 y 和测量矩阵 Φ 传输出去，接收方很难恢复 x ，存在信息损失

压缩感知

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

- 假设存在某个线性变换 $\Psi \in \mathbb{R}^{m \times m}$ ，使得 x 可以表示为 $x = \Psi s$ ，则 y 表示为：

$$y = \Phi \Psi s = A s, \text{ 其中 } A = \Phi \Psi \in \mathbb{R}^{n \times m}$$

- 若能根据 y 恢复出 s ，则可以通过 $x = \Psi s$ 来恢复出信号 x ，然而上式中恢复信号 s 这个逆问题仍是欠定的，并没有解决任何问题。
- 然而若 s 具有稀疏性，则这个问题就能很好的得以解决。因为稀疏性使得未知因素的影响大为减少，此时式中的 Ψ 称为稀疏基， A 的作用则类似于字典，能将信号转换为稀疏表示

压缩感知限定等距性理论

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

- 限定等距性 (Restrict Isometry Property, RIP) : 对于大小为 $n \times m$ ($n \ll m$) 的矩阵 A , 若存在常数 $\delta_k \in (0,1)$ 使得对于任意向量 s 和 A 的所有子矩阵 $A_k \in \mathbb{R}^{n \times k}$ 有

$$(1 - \delta_k) \|s\|_2^2 \leq \|A_k s\|_2^2 \leq (1 + \delta_k) \|s\|_2^2$$

则称 A 满足 **k 限定等距性 (k - RIP)**。此时可通过下面的优化问题近乎完美地从 y 中恢复出稀疏信号 s , 进而恢复出 x :

$$\min_s \|s\|_0 \quad \text{s.t. } y = As$$

- 上中涉及 l_0 范数最小化, 是个 NP 难度问题, 很难求解, 可转化为 l_1 范数优化问题:


$$\min_s \|s\|_1 \quad \text{s.t. } y = As$$

稀疏性 (Sparsity)

□ 数据中大多数元素为0的数据

稀疏矩阵、稀疏向量、稀疏信号

$$\begin{pmatrix} 10 & 20 & 0 & 0 & 0 & 0 \\ 0 & 30 & 0 & 40 & 0 & 0 \\ 0 & 0 & 50 & 60 & 70 & 0 \\ 0 & 0 & 0 & 0 & 0 & 80 \end{pmatrix}$$



- l_0 范数是向量中非0元素的个数,如果我们用 l_0 范数来规则化一个向量 v , 就是希望 v 的大部分元素都是0, 即让 v 是稀疏的
- l_1 范数是向量元素的绝对值之和, l_0 范数很难优化求解, 所以往往用 l_1 范数代替 l_0 范数—— **l_1 范数是 l_0 范数的最优凸近似**

为什么需要稀疏性？

□ 实现更有效的特征选择

一般来说，输入中的很多元素与最终输出关系不大或者不提供有用信息，在进行模型测试时会起干扰作用，如果特征稀疏，尽可能保留有效信息则可提高特征选择的性能

□ 可解释性

稀疏性使模型更容易解释，例如：患某种病的概率是 y ，我们收集到的数据 x 是1000维的，也就是我们需要寻找这1000种因素到底是怎么影响患上这种病的概率的；如果只有很小一部分因素的权重不为0，则很容易分析关系

稀疏表示与字典学习

❑ 稀疏表示(sparse representation)是用有限个特征向量(基)来表示信号，字典学习(dictionary learning)是根据信号自身的结构特征来学习得到这些特征向量(基)

❑ 一个数据集矩阵 D ，每行对应一个样本，每列对应一个特征

例如：在文本分类中，将每个文档看作一个样本，每个字（词）作为一个特征，字（词）在文档中出现的频率或次数作为特征的取值； D 对应的矩阵的每行是一个文档，每列是一个字（词），行、列交汇处就是某字（词）在某文档中出现的频率或次数

这种方式往往造成特征向量的维度过大。以汉语为例，《康熙字典》中有47035个汉字，意味着矩阵可有4万多列，即使在《现代汉语常用字表》中，该矩阵有3500列。然而，给定一个文档，相当多的字是不出现在这个文档中的，于是矩阵的每一行有大量0元素；对不同的文档，0元素出现的列往往不同

❑ 能否将普通的非稀疏数据集 D 转化为“稀疏表示”形式，从而享有稀疏性带来的好处呢？为普通稠密表达的样本学习一个字典，将样本转化为合适的稀疏表示形式，从而简化学习任务，降低模型复杂度，称字典学习，亦称稀疏编码(sparse coding)

稀疏表示与字典学习

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

□ 给定数据集 $\{x_1, x_2, \dots, x_m\}$ ，字典学习最简单的形式为

$$\min_{B, \alpha_i} \sum_{i=1}^m \|x_i - B\alpha_i\|_2^2 + \lambda \sum_{i=1}^m \|\alpha_i\|_1$$

- 其中 $B \in \mathbb{R}^{d \times k}$ 为字典矩阵， k 称为字典的词汇量，通常由用户指定， $\alpha_i \in \mathbb{R}^k$ 为样本 $x_i \in \mathbb{R}^d$ 的稀疏表示。
- 上式第一项希望由 α_i 能很好重构 x_i ，第二项希望 α_i 尽量稀疏

稀疏表示与字典学习

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

- 采用变量交替优化的策略来求解上式
- 第一步，固定住字典B，将上式按分量展开，其中不涉及 $\alpha_i^u \alpha_i^v (u \neq v)$ 这样的交叉项，可以参照LASSO (Least absolute shrinkage and selection operator)的解法来求解下式，从而为每个样本 x_i 找到相应的 α_i ：

$$\min_{\alpha_i} \|x_i - B\alpha_i\|_2^2 + \lambda \|\alpha_i\|_1$$

- 第二步，以 α_i 为初值来更新字典B，此时可将上式写为

$$\min_B \|X - BA\|_F^2$$

其中 $X = (x_1, x_2, \dots, x_m) \in \mathbb{R}^{d \times m}$, $A = (\alpha_1, \alpha_2, \dots, \alpha_m) \in \mathbb{R}^{k \times m}$, $\|\cdot\|_F^2$ 是矩阵的 Frobenius范数

人脸识别

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

- 目标识别的基本问题：从 k 个不同的目标类中使用经过标记的训练样本来正确地确定一个新的测试样本所属的类
- 设 $A_i = [v_{i,1}, v_{i,2}, \dots, v_{i,n_i}] \in \mathbb{R}^{m \times n_i}$ 是第 i 类中的 n_i 个训练样本集合
- 测试样本可以表达为训练样本的稀疏线性组合：给定目标类 i 的训练样本 $A_i \in \mathbb{R}^{m \times n_i}$ ，任何新的来自同一类的(测试)样本 $y \in \mathbb{R}^m$ 位于与目标 i 相关的训练样本张成的线性空间内：

$$y = \alpha_{i,1}v_{i,1} + \alpha_{i,2}v_{i,2} + \dots + \alpha_{i,n_i}v_{i,n_i}$$

$$\alpha_{i,j} \in \mathbb{R}, \quad j = 1, \dots, n_i$$

John Wright et al, Robust Face Recognition via Sparse Representation, TPAMI 2009

人脸识别

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

- 由于测试样本的类别 i 一开始是未知的，我们为整个训练集定义一个新的矩阵 A ，即所有 k 个目标类的 n 个训练样本的连接： $A = [A_1, A_2, \dots, A_k] = [v_{1,1}, v_{1,2}, \dots, v_{k,n_k}]$

- 那么， y 的线性表示可以用所有训练样本重写为：


$$y = Ax_0 \in \mathbb{R}^m,$$

其中 $x_0 = [0, \dots, 0, \alpha_{i,1}, \alpha_{i,2}, \dots, \alpha_{i,n_i}, 0, \dots, 0]^T \in \mathbb{R}^n$ 是一个系数向量，除与第 i 类相关的项外，其余项均为零

- 向量 x_0 的分量表达了测试样本 y 的类别，可以通过求解线性方程组 $y = Ax_0$ 来获得

基于稀疏表示的目标分类-人脸识别

西安交通大学人工智能学院魏平编写。课程资料，请勿外传



西安交

人脸识别

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

- 如果 $m > n$ ，方程组 $y = Ax_0$ 是超定的(overdetermined)，通常可以找到正确的 x_0 作为它的唯一解
- 然而在人脸识别中，系统 $y = Ax_0$ 通常是欠定的(underdetermined)，因此，它的解通常不是唯一的，通过选择最小化 ℓ_2 -norm来解决：

$$(\ell^2): \hat{x}_2 = \arg \min \|x\|_2 \\ s.t. Ax = y$$

- 虽然这个优化问题很容易解决(通过A的伪逆pseudoinverse)，但解 $\hat{x}_2$ 对于识别测试样本 y 并不是特别有用， $\hat{x}_2$ 通常是稠密的，有很大的非零项，对应于来自许多不同类的训练样本

人脸识别

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

- 解决：仅使用来自同一类的训练样本，就可以充分表示一个有效的测试样本 y 。如果目标类 k 的数量相当大，这种表示自然是稀疏的。例如，如果 $k = 20$, x_0 中只有5%的元素是非零的。恢复的 x_0 越稀疏，越容易准确确定测试样本 y 的标识。
- 寻找 $y = Ax$ 的稀疏解，通过解决以下优化问题：

$$(\ell^0): \hat{x}_0 = \arg \min \|x\|_0$$

$$\text{s.t. } Ax = y$$

其中 $\|\cdot\|_0$ 代表 ℓ_0 -norm，它计算一个向量中非零元素的数量

基于 ℓ_1 -norm的稀疏解

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

- 稀疏表示和压缩感知理论表明,如果 x_0 的解是足够稀疏的, 那么 ℓ_0 最小化问题的解等于以下 ℓ_1 最小化问题的解:

$$(\ell^1): \hat{x}_1 = \arg \min \|x\|_1 \\ s. t. Ax = y$$

- 处理小稠密噪声:以上建模, 我们假设 $y = Ax_0$ 是正确的。由于真实数据是有噪声的, 因此不能将测试样本准确地表示为训练样本的稀疏叠加。模型 $y = Ax_0$ 可以修改为显式地考虑小的可能稠密的噪声: $y = Ax_0 + z$, 其中 $z \in \mathbb{R}^m$ 是有界 $\|z\|_2 < \varepsilon$ 的噪声项

$$(\ell_s^1): \hat{x}_1 = \arg \min \|x\|_1 \\ s. t. \|Ax - y\|_2 \leq \varepsilon$$

基于稀疏表示的分类


- 理想情况下，估计值 $\hat{x}_1$ 中的非零项都将与来自单个目标类 i 的 A 的列相关联，则我们可以轻松地将测试样本 y 分配给这个类。然而，噪声和建模误差可能导致与多个目标类相关的小的非零项
- 对于每个 i 类，让 $\delta_i: \mathbb{R}^n \rightarrow \mathbb{R}^n$ 为选择与第 i 类相关系数的**特征函数**。对 $x \in \mathbb{R}^n$ ， $\delta_i(x) \in \mathbb{R}^n$ 是一个新的向量，它唯一的非零元素是 x 中与类 i 相关的元素
- 仅使用与第 i 类相关的系数，就可以近似给定的测试样本 y 为 $\hat{y}_i = A\delta_i(\hat{x}_1)$ 。然后，我们根据这些近似对 y 进行分类，将其分配给使 y 和 $\hat{y}_i$ 之间的残差最小的目标类：

$$\min_i r_i(y) = \|y - A\delta_i(\hat{x}_1)\|_2$$

对遮挡或损坏的鲁棒性

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

- 在许多实际的人脸识别场景中，测试图像 y 可能会被部分损坏或遮挡



对遮挡或损坏的鲁棒性

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

- 在部分损坏或遮挡情况下，将上述线性模型 $y = Ax_0$ 修改为：

$$y = y_0 + e_0 = Ax_0 + e_0$$

其中 $e_0 \in \mathbb{R}^m$ 是错误向量， e_0 的非零项表达 y 中被破坏或遮挡的像素，非零项比列为 ρ

- 扩展稀疏表示分类框架来处理遮挡：假设损坏的像素是图像中相对较小的一部分。错误向量 e_0 ，就像向量 x_0 一样，有sparse非零项。因为 $y = Ax_0$ ，我们可以把上式写成：

$$y = [A, I] \begin{bmatrix} x_0 \\ e_0 \end{bmatrix} = Bw_0, \text{ 其中 } B = [A, I] \in \mathbb{R}^{m \times (n+m)}$$

对遮挡或损坏的鲁棒性

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

□ 从以下扩展的 ℓ_1 -最小化问题中恢复最稀疏解 w_0 ：

$$(\ell_e^1): \hat{w}_1 = \arg \min \|w\|_1 \\ s.t. Bw = y$$

即在算法1中，将图像矩阵A替换为扩展矩阵B， x 替换为 w

- 一旦稀疏解 $\hat{w}_1 = [\hat{x}_1, \hat{e}_1]$ 被计算，设 $y_r = y - \hat{e}_1$ 恢复被遮挡或损坏的目标的干净图像
- 为了识别目标，我们对算法1中的残差 $r_i(y)$ 进行了轻微的修改，对恢复后的图像 y_r 进行计算：

$$r_i(y) = \|y_r - A\delta_i(\hat{x}_1)\|_2 = \|y - \hat{e}_1 - A\delta_i(\hat{x}_1)\|_2$$

人脸识别

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

- ❑ 人脸识别中的两个关键问题：特征提取和对遮挡的鲁棒性
- ❑ 特征提取：
 - 目标图像的哪些低维特征对分类最有相关性或最有信息性。大量的文献致力于研究各种特征转换，将高维测试图像投影到低维特征空间
 - 压缩感知理论表明，**特征空间的精确选择**不再是关键：即使随机特征也包含足够的信息来恢复稀疏表示，从而正确地分类任何测试图像。关键是特征空间的维数要足够大，而且稀疏表示的计算要正确

总结：

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

- 利用稀疏性对人脸图像等高维数据的高性能分类至关重要
- 适当地利用稀疏性
- 特征的选择变得不像使用的特征的数量那么重要
- 对遮挡和破坏问题进行统一、稳健的处理



西安交通大学
XI'AN JIAOTONG UNIVERSITY

IAIR Est. 1986

Institute of
Artificial Intelligence
and Robotics



人工智能学院
College of Artificial Intelligence, XJTU

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

The End

西安交通