



西安交通大学
XI'AN JIAOTONG UNIVERSITY

IAIR Est.
1986

Institute of
Artificial Intelligence
and Robotics



人工智能学院
College of Artificial Intelligence, XJTU

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

《高级机器学习》第六章

概率采样与蒙特卡罗方法 Probabilistic Sampling and Monte Carlo Methods


魏平

西安交通大学人工智能学院
人工智能与机器人研究所


什么是采样

西安交通大学人工智能学院魏平编写。课程资料，请勿外传


□ 求矩形中不规则图形包围的面积



不规则图形



均匀撒点




数点的个数

什么是采样

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

- 计算函数 $f(\mathbf{z})$ 关于分布 $p(\mathbf{z})$ 的期望,直接计算很困难

$$\mathbb{E}(f) = \int f(\mathbf{z})p(\mathbf{z})d\mathbf{z}$$




- 如果有服从 $p(\mathbf{z})$ 的 L 个独立样本 $\mathbf{z}^{(l)} (l = 1, \dots, L)$, 可近似计算

$$\hat{f} = \frac{1}{L} \sum_{l=1}^L f(\mathbf{z}^{(l)})$$

什么是采样

- 从一个分布中生成一批服从该分布的样本，该过程叫**采样**
- 采样本质上是对随机现象的模拟，根据给定的概率分布，来模拟产生一个对应的随机事件。采样可以让人们对随机事件及其产生过程有更直观的认识



函数 $f(z)$ 的期望的图形化表示， $f(z)$ 的期望是关于概率分布 $p(z)$ 计算得到的

采样的作用

- 机器学习中的某些任务转化为某些函数在特定分布下的积分或期望，或者是求某些随机变量或参数在给定数据下的后验分布等，可能会遇到样本量过大或模型结构复杂导致的求解难度大、没有显式解析解等问题。这种情况下，可以利用采样方法进行模拟，从而对这些复杂模型进近似求解或推理
- 采样得到的样本集也可以看作是一种非参数模型，即用较少量的样本点（经验分布）来近似总体分布，并刻画总体分布中的不确定性


$$\mathbb{E}(f) = \int f(\mathbf{z})p(\mathbf{z})d\mathbf{z}$$

$$W^* = \arg \max \pi(W | \mathbf{I}) = \arg \max p(\mathbf{I} | W)p(W)$$

蒙特卡罗方法起源

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

- 现代蒙特卡罗方法于20世纪40年代由美国科学家乌拉姆和冯·诺伊曼提出
- 冯·诺伊曼用摩纳哥的著名赌场 Monte Carlo来命名这种方法
- 1777年，法国数学家布冯（Georges Louis Leclerc de Buffon, 1707—1788）提出用投针实验的方法求圆周率 π ，被认为是蒙特卡罗方法的起源



冯·诺伊曼



摩纳哥的蒙特卡罗赌场

蒙特卡罗方法的概念

- ❑ 蒙特卡罗方法（Monte Carlo Methods）是一种通过大量随机采样来近似计算结果的数值方法，核心是用“随机性”解决“确定性”难题；以概率理论为指导，应用随机数进行模拟试验，用于一些解析法难以求解甚至不可求解的问题
- ❑ 蒙特卡罗方法主要分为三步
 1. **构建模型**：将需要解决的问题（如计算面积、预测风险）转化为一个可通过随机变量描述的数学模型
 2. **随机采样**：通过计算机生成大量符合模型规则的随机数据，模拟现实中的不确定性过程
 3. **统计计算**：对采样得到的结果进行统计分析（如求平均值、计数频率），最终得到问题的近似解

蒙特卡罗方法的概念

- 对于大多数实际应用中的概率模型来说，无法精确计算其和或积分，可以采取基于数值采样的近似推断方法
- 问题：寻找某个定义在概率分布 $p(z)$ 上的函数 $f(z)$ 的期望，即计算：
$$\mathbb{E}[f] = \int f(z)p(z)dz$$
- 对这个问题，蒙特卡罗方法的一种可能是从概率分布 $p(z)$ 中独立抽取 l 个样本 $z^{(1)}, z^{(2)}, \dots, z^{(l)}$ ，通过有限和的方式计算得到一个经验平均值

$$\hat{f} = \frac{1}{L} \sum_{l=1}^L f(z^{(l)})$$

CONTENTS



西安交通大学人工智能学院魏平编写。课程资料，请勿外传

IAIR Est.
1986

Institute of
Artificial Intelligence
and Robotics




人工智能学院
College of Artificial Intelligence, XJTU

常见的采样方法

- 均匀分布采样
- 逆变换采样
- 拒绝采样
- 重要采样
- Metropolis-Hasting方法
- 吉布斯采样

均匀分布采样

- 均匀分布是指整个样本空间中的每一个样本点对应的概率(密度)都是相等的；根据样本空间是否连续，又分为离散均匀分布和连续均匀分布
- 均匀分布可以算作是最简单的概率分布，几乎是所有采样算法都需要用的基本操作



- 区间 $[a,b]$ 均匀分布的概率密度

$$p(x) = \begin{cases} \frac{1}{b-a} & a \leq x \leq b \\ 0 & \text{elsewhere} \end{cases}$$

- 均匀分布的累积分布函数

$$P(X) = \begin{cases} 0 & X < a \\ \frac{X-a}{b-a} & a \leq X < b \\ 1 & X \geq b \end{cases}$$

均匀分布采样

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

- 用线性同余法生成区间 $[0, m - 1]$ 上的伪随机数序列：

$$x_{t+1} = (a \cdot x_t + c) \bmod m$$

模 $m > 0$, 系数 $0 < a < m$, 增量 $0 \leq c < m$
种子 x_0 满足 $0 \leq x_0 < m$

例： $a = 3, c = 0, m = 7, x_0 = 6$

$$x_1 = (3 \cdot 6 + 0) \bmod 7 = 4$$

$$x_2 = (3 \cdot 4 + 0) \bmod 7 = 5$$

$$x_3 = (3 \cdot 5 + 0) \bmod 7 = 1$$

...

4、5、1、3、2、6、4、5、1、3、2、6...

- 一般计算机的程序都是确定性的，无法产生真正意义上的完全均匀分布的随机数，只能产生伪随机数

CONTENTS



西安交通大学人工智能学院魏平编写。课程资料，请勿外传

IAIR Est.
1986

Institute of
Artificial Intelligence
and Robotics



人工智能学院
College of Artificial Intelligence, XJTU

常见的采样方法

- 均匀分布采样
- 逆变换采样
- 拒绝采样
- 重要采样
- Metropolis-Hasting方法
- 吉布斯采样

逆变换采样

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

- 逆变换采样，又称为逆概率积分变换、逆变换法，是伪随机数采样的一种基本方法，**从基本的均匀分布产生简单分布**
- **回顾—累计分布函数**

- 随机变量 x 位于区间 $[a, b]$ 的概率

$$P(x \in [a, b]) = \int_a^b p(x) dx$$

- 随机变量 x 的累积分布函数为

$$P(x \leq X) = P(X) = \int_{-\infty}^x p(x) dx$$

逆变换采样

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

- **定理：** 设 y 是一个连续随机变量，概率密度函数为 $p(y)$ ，累计分布函数为 $h(y) = P(y)$ ，则 $z = h(y)$ 是定义在区间 $0 \leq z \leq 1$ 上的均匀分布，即 $p(z) = 1$ ($0 \leq z \leq 1$)
- **证明：** $h(y)$ 是累计分布函数，则 $0 \leq z = h(y) \leq 1$ ，且 $h(y)$ 是单调递增函数

z 的累计分布函数：

单调递增函数


$$P(z \leq Z) = P(h(y) \leq Z) = P(y \leq h^{-1}(Z)) = h(h^{-1}(Z)) = Z$$

$$p(z) = \frac{dP(Z)}{dZ} = 1 \quad (0 \leq z \leq 1)$$

逆变换采样

□ 待采样的目标分布为 $p(x)$, 它的累积分布函数为 $z = \Phi(X) = \int_{-\infty}^X p(x)dx$, 则逆变换采样法步骤为:

- ① 从均匀分布 $U(0,1)$ 产生一个随机数 z_i ;
- ② 计算逆函数 $X_i = \Phi^{-1}(z_i)$; 循环上述步骤, 产生更多样本



● 例子: 指数分布密度函数

$$p(x) = \lambda \exp(-\lambda x) \quad (0 \leq x < \infty)$$

● 累积分布函数

$$z = \Phi(X) = 1 - \exp(-\lambda X)$$

● 逆变换

$$X = -\lambda^{-1} \ln(1 - z)$$

CONTENTS



西安交通大学人工智能学院魏平编写。课程资料，请勿外传

IAIR Est.
1986

Institute of
Artificial Intelligence
and Robotics




人工智能学院
College of Artificial Intelligence, XJTU

常见的采样方法

- 均匀分布采样
- 逆变换采样
- 拒绝采样
- 重要采样
- Metropolis-Hasting方法
- 吉布斯采样

拒绝采样(Rejection Sampling)


- 拒绝采样，又称为接受-拒绝采样，基本思想是用一“更大的的概率分布”或“更简单的概率分布” $q(z)$ 覆盖原本的概率分布，这个更简单的概率分布容易采样（如正态分布）
- $p(z) = \frac{1}{z_p} \tilde{p}(z)$ 为**采样分布**， $\tilde{p}(z)$ 为已知分布， z_p 归一化因子
- 引入较简单分布 $q(z)$ ，称为**提议分布**，从中可以较容易采样
- 引入常数 k ，对任意 z 满足 $kq(z) \geq \tilde{p}(z)$ ， $kq(z)$ 称为**比较函数**



拒绝采样(Rejection Sampling)


❑ 拒绝采样方法的步骤：

- ① 从 $q(z)$ 采样生成一个样本 z_0
- ② 生成区间 $[0, kq(z_0)]$ 上的均匀分布的一个样本 u_0
- ③ 如果 $u_0 > \tilde{p}(z_0)$, 则该样本被拒绝；否则 z_0 被接受
- ④ 重复以上过程得到 $[z_0, z_1, \dots, z_n]$ 即是对 $p(z)$ 的一个近似




拒绝采样的直观理解


西安交通大学人工智能学院魏平编写。课程资料，请勿外传




1.
从该分布中采样



2.
矩形套分布曲线



3.
向矩形里均匀随机投点




4.
分布曲线上下点



拒绝采样的直观理解

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

只保留密度曲线下侧的点



把每个蓝点的横坐标提取出来，这些横坐标所构成的样本就是我们的目标样本



拒绝采样


- 在上述拒绝采样方法中， z 的原始值从概率分布 $q(z)$ 中生成，这些样本之后被接受的可能性为 $\frac{\tilde{p}(z)}{kq(z)}$ ，因此，样本被接受的平均概率为：

$$p(\text{accept}) = \int \left\{ \frac{\tilde{p}(z)}{kq(z)} \right\} q(z) dz = \frac{1}{k} \int \tilde{p}(z) dz$$

- 原则上 k 可以取得很大，从而满足总能全覆盖，但是不难发现， k 取得越大，拒绝概率也更高；因此，选取的 k 要尽可能的小，并使得 $kq(z)$ 恰好能覆盖 $\tilde{p}(z)$


拒绝采样演示

西安交通大学人工智能学院魏平编写。课程资料，请勿外传



拒绝采样的一个例子

- Gamma分布的形式为：
$$\text{Gam}(z|a, b) = \frac{b^a z^{a-1} \exp(-bz)}{\Gamma(a)}$$
- 对于 $a > 1$ 的情形，它的形状是钟形曲线。使用柯西分布作为提议分布，柯西分布也是钟形曲线，并且易于采样
- 为使Gamma分布曲线能被完全覆盖，取 $q(z) = \frac{k}{1 + \frac{(z-c)^2}{b^2}}$
- 绿色曲线表示Gamma分布的图像，红色曲线表示放缩后的柯西提议分布。从Gamma分布中抽取的样本可以通过从柯西分布中采样然后使用拒绝采样准则的方法得到



CONTENTS



西安交通大学人工智能学院魏平编写。课程资料，请勿外传

IAIR Est.
1986

Institute of
Artificial Intelligence
and Robotics



人工智能学院
College of Artificial Intelligence, XJTU

常见的采样方法

- 均匀分布采样
- 逆变换采样
- 拒绝采样
- 重要采样
- Metropolis-Hasting方法
- 吉布斯采样

重要采样(Importance Sampling)


- ❑ 重要采样方法提供了一种直接近似期望的框架，它本身不是一种从概率分布 $p(z)$ 中采样的方法
- ❑ 重要采样基于以下假设：直接从 $p(z)$ 中采样非常困难或无法完成，但对于任一给定的 z 值，可以很容易地计算 $p(z)$ 的值
- ❑ 仿照拒绝采样的思路，可以利用提议分布;与拒绝采样不同的是：提议分布要使用最优的采样函数，不用一定全部覆盖原分布函数；并且所有生成的样本都会被保留

重要采样

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

- 计算函数 $f(\mathbf{z})$ 关于分布 $p(\mathbf{z})$ 的期望,直接计算很困难

$$\mathbb{E}(f) = \int f(\mathbf{z})p(\mathbf{z})d\mathbf{z}$$



- 如果有服从 $p(\mathbf{z})$ 的 L 个独立样本 $\mathbf{z}^{(l)} (l = 1, \dots, L)$, 可近似计算

$$\hat{f} = \frac{1}{L} \sum_{l=1}^L f(\mathbf{z}^{(l)}) \quad \text{或} \quad \mathbb{E}(f) \approx \sum_{l=1}^L p(\mathbf{z}^{(l)}) f(\mathbf{z}^{(l)})$$

重要采样

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

- 以上方法明显的一个缺陷是当 $\mathbf{z}$ 的维度较高时，需要采样的点数会很多；其次，在高维空间中的均匀采样效率很低
- 我们希望选择落在 $p(\mathbf{z})$ 较大的区域内的点或者 $f(\mathbf{z})p(\mathbf{z})$ 较大
- 可以用从提议分布 $q(\mathbf{z})$ 采样的样本 $\mathbf{z}^{(l)} (l = 1, \dots, L)$ 表达期望

$$\mathbb{E}(f) = \int f(\mathbf{z})p(\mathbf{z})d\mathbf{z} = \int f(\mathbf{z})\frac{p(\mathbf{z})}{q(\mathbf{z})} q(\mathbf{z})d\mathbf{z} \approx \frac{1}{L} \sum_{l=1}^L \frac{p(\mathbf{z}^{(l)})}{q(\mathbf{z}^{(l)})} f(\mathbf{z}^{(l)})$$

重要采样

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

- $r_l = \frac{p(\mathbf{z}^{(l)})}{q(\mathbf{z}^{(l)})}$ 称为重要性权重，修正由于从其他概率分布中采样引入的偏差
- 引入 $p(\mathbf{z}) = \frac{1}{Z_p} \tilde{p}(\mathbf{z})$, $q(\mathbf{z}) = \frac{1}{Z_q} \tilde{q}(\mathbf{z})$

$$\begin{aligned}\mathbb{E}(f) &= \int f(\mathbf{z}) p(\mathbf{z}) d\mathbf{z} \\ &= \frac{Z_q}{Z_p} \int f(\mathbf{z}) \frac{\tilde{p}(\mathbf{z})}{\tilde{q}(\mathbf{z})} q(\mathbf{z}) d\mathbf{z} \\ &\approx \frac{Z_q}{Z_p} \frac{1}{L} \sum_{l=1}^L \tilde{r}_l f(\mathbf{z}^{(l)})\end{aligned}$$

$$\tilde{r} = \frac{\tilde{p}(\mathbf{z})}{\tilde{q}(\mathbf{z})}$$

重要采样

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

□ 计算

$$\begin{aligned}\frac{Z_p}{Z_q} &= \frac{1}{Z_q} \int \tilde{p}(\mathbf{z}) d\mathbf{z} = \frac{1}{Z_q} \int \frac{\tilde{p}(\mathbf{z})}{\tilde{q}(\mathbf{z})} q(\mathbf{z}) d\mathbf{z} \\ &= \int \frac{\tilde{p}(\mathbf{z})}{\tilde{q}(\mathbf{z})} q(\mathbf{z}) d\mathbf{z} & \tilde{r} &= \frac{\tilde{p}(\mathbf{z})}{\tilde{q}(\mathbf{z})} \\ &\approx \frac{1}{L} \sum_{l=1}^L \tilde{r}_l\end{aligned}$$

□ 因此

$$\mathbb{E}(f) \approx \sum_{l=1}^L \omega_l f(\mathbf{z}^{(l)}) \quad \omega_l = \frac{\tilde{r}_l}{\sum_m \tilde{r}_m} = \frac{\tilde{p}(\mathbf{z}^{(l)})/q(\mathbf{z}^{(l)})}{\sum_m \tilde{p}(\mathbf{z}^{(m)})/q(\mathbf{z}^{(m)})}$$

CONTENTS



西安交通大学人工智能学院魏平编写。课程资料，请勿外传

IAIR Est.
1986

Institute of
Artificial Intelligence
and Robotics



人工智能学院
College of Artificial Intelligence, XJTU

常见的采样方法

- 均匀分布采样
- 逆变换采样
- 拒绝采样
- 重要采样
- Metropolis-Hasting方法
- 吉布斯采样

Metropolis算法

- 在基本Metropolis算法中，假设提议分布是对称的，即 $q(\mathbf{z}_A | \mathbf{z}_B) = q(\mathbf{z}_B | \mathbf{z}_A)$
- 候选样本的接受概率定义为 $A(\mathbf{z}^*, \mathbf{z}^{(\tau)}) = \min\{1, \frac{\tilde{p}(\mathbf{z}^*)}{\tilde{p}(\mathbf{z}^{(\tau)})}\}$

Metropolis算法流程：

初始化：最大迭代次数 T ，需要样本数目 n ，初始化样本 $\mathbf{z}^{(0)} \sim q(\mathbf{z})$ ，循环迭代以下过程：

- ① 从条件概率分布 $q(\mathbf{z} | \mathbf{z}^{(\tau)})$ 中采样得到样本值 $\mathbf{z}^*$
- ② 从均匀分布中采样 $u \sim (0,1)$
- ③ 如果 $A(\mathbf{z}^*, \mathbf{z}^{(\tau)}) > u$ ，则接受 $\mathbf{z}^*$ ，即 $\mathbf{z}^{(\tau+1)} = \mathbf{z}^*$ ；否则 $\mathbf{z}^*$ 被舍弃，且 $\mathbf{z}^{(\tau+1)} = \mathbf{z}^{(\tau)}$ ；
(实现时只保留一个重复样本，记录重复次数)
- ④ 如果未达到最大迭代次数，循环上述过程；否则停止

输出：根据需要截取尾部 n 个样本

Metropolis-Hastings算法

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

□ 在基本Metropolis算法中，假设提议分布是对称的，即 $q(\mathbf{z}_A | \mathbf{z}_B) = q(\mathbf{z}_B | \mathbf{z}_A)$ ，Metropolis-Hastings算法无此限制

□ 接受概率定义为 $A(\mathbf{z}^*, \mathbf{z}^{(\tau)}) = \min\{1, \frac{\tilde{p}(\mathbf{z}^*)q(\mathbf{z}^{(\tau)}|\mathbf{z}^*)}{\tilde{p}(\mathbf{z}^{(\tau)})q(\mathbf{z}^*|\mathbf{z}^{(\tau)})}\}$

□ **Metropolis-Hastings算法流程：**

初始化： 最大迭代次数 T ，需要样本数目 n ，初始化样本 $\mathbf{z}^{(0)} \sim q(\mathbf{z})$ ，循环迭代以下过程：

① 从条件概率分布 $q(\mathbf{z} | \mathbf{z}^{(\tau)})$ 中采样得到样本值 $\mathbf{z}^*$

② 从均匀分布中采样 $u \sim (0,1)$

③ 如果 $A(\mathbf{z}^*, \mathbf{z}^{(\tau)}) > u$ ，则接受 $\mathbf{z}^*$ ，即 $\mathbf{z}^{(\tau+1)} = \mathbf{z}^*$ ；否则 $\mathbf{z}^*$ 被舍弃，且 $\mathbf{z}^{(\tau+1)} = \mathbf{z}^{(\tau)}$ ；

④ 如果未达到最大迭代次数，循环上述过程；否则停止

输出： 根据需要截取尾部 n 个样本

CONTENTS



西安交通大学人工智能学院魏平编写。课程资料，请勿外传

IAIR Est.
1986

Institute of
Artificial Intelligence
and Robotics



人工智能学院
College of Artificial Intelligence, XJTU

常见的采样方法

- 均匀分布采样
- 逆变换采样
- 拒绝采样
- 重要采样
- Metropolis-Hasting方法
- 吉布斯采样

Gibbs采样

- Gibbs 采样是一种广泛应用的马尔可夫链蒙特卡罗算法，也可以被看作 Metropolis-Hasting 算法的一个具体情形
- 待采样分布为 $p(\mathbf{z}) = p(z_1, z_2, \dots, z_M)$
- 吉布斯采样每一步将一个变量的值替换为以剩余变量的值为条件，从这个概率分布中采样的那个变量的值。即将 z_i 替换为从概率分布 $p(z_i | \mathbf{z}_{\setminus i})$ 中抽取的值，其中 z_i 表示 $\mathbf{z}$ 的第 i 个元素， $\mathbf{z}_{\setminus i}$ 表示 $z_1, \dots, z_M$ 去掉 z_i 这一项



Josiah Willard Gibbs
1839–1903

Gibbs spent almost his entire life living in a house built by his father in New Haven, Connecticut. In 1863, Gibbs was granted the first PhD in engineering in the United States, and in 1871 he was appointed to

the first chair of mathematical physics in the United

States at Yale, a post for which he received no salary because at the time he had no publications. He developed the field of vector analysis and made contributions to crystallography and planetary orbits. His most famous work, entitled *On the Equilibrium of Heterogeneous Substances*, laid the foundations for the science of physical chemistry.

Gibbs采样

- 例如，假设有一个在三个变量上的概率分布 $p(z_1, z_2, z_3)$
- 首先，将 $z_1^{(\tau)}$ 替换为新值 $z_1^{(\tau+1)}$ ，这个新值是从条件概率分布 $p(z_1|z_2^{(\tau)}, z_3^{(\tau)})$ 中采样得到的
- 接下来，将 $z_2^{(\tau)}$ 替换为 $z_2^{(\tau+1)}$ ，这个新值是从条件概率分布 $p(z_2|z_1^{(\tau+1)}, z_3^{(\tau)})$ 中采样得到的，即 z_1 的新值可以再接下来的采样步骤中直接使用
- 然后用 $z_3^{(\tau+1)}$ 更新 $z_3^{(\tau)}$ ，其中 $z_3^{(\tau+1)}$ 是从 $p(z_3|z_1^{(\tau+1)}, z_2^{(\tau+1)})$ 中进行采样的
- 以此类推，在这三个变量之间进行循环

Gibbs采样

西安交通大学人工智能学院魏平编写。课程资料，请勿外传

Gibbs Sampling


1. Initialize $\{z_i : i = 1, \dots, M\}$
2. For $\tau = 1, \dots, T$:
 - Sample $z_1^{(\tau+1)} \sim p(z_1 | z_2^{(\tau)}, z_3^{(\tau)}, \dots, z_M^{(\tau)})$.
 - Sample $z_2^{(\tau+1)} \sim p(z_2 | z_1^{(\tau+1)}, z_3^{(\tau)}, \dots, z_M^{(\tau)})$.
 - $\vdots$
 - Sample $z_j^{(\tau+1)} \sim p(z_j | z_1^{(\tau+1)}, \dots, z_{j-1}^{(\tau+1)}, z_{j+1}^{(\tau)}, \dots, z_M^{(\tau)})$.
 - $\vdots$
 - Sample $z_M^{(\tau+1)} \sim p(z_M | z_1^{(\tau+1)}, z_2^{(\tau+1)}, \dots, z_{M-1}^{(\tau+1)})$.

蒙特卡罗方法应用1:采样和模拟


西安交通大学人工智能学院魏平编写。课程资料，请勿外传

- 模拟一个系统及其概率分布 $x \sim p(x)$
- 图像表达为一个吉布斯分布


$$\pi(\mathbf{I}_\Lambda; \Theta) = \frac{1}{Z} \exp\{-\langle \Theta, H(\mathbf{I}_\Lambda) \rangle\}$$




(a)




(b)




(c)



(d)



(e)



(f)

蒙特卡罗方法应用2:估算未知量


能学院魏平编写。课程资料，请勿外传

- 在高维空间中计算一个函数的积分

$$c = \int_{\Omega} \pi(\mathbf{x}) f(\mathbf{x}) d\mathbf{x}$$

- 利用粒子滤波进行目标跟踪

$$\pi(x(t+1) | \mathbf{I}[0, t+1]) = \int g(\mathbf{I}(t+1) | x(t+1)) p(x(t+1) | x(t)) \cdot \pi(x(t) | \mathbf{I}[0, t]) dx(t)$$



西安交通大学

蒙特卡罗方法应用2:估算未知量

□ 利用粒子滤波进行场景理解



蒙特卡罗方法应用2:估算未知量

能学院魏平编写。课程资料，请勿外传



利用粒子滤波进行场景理解

$$\begin{aligned}
 p(l_{1:k}|r_{1:k}) &\propto p(r_k|l_{1:k}, r_{1:k-1})p(l_{1:k}|r_{1:k-1}) \\
 &= p(a_k, x_k|l_{1:k}, a_{1:k-1}, x_{1:k-1})p(l_{1:k}|r_{1:k-1}) \\
 &= p(a_k|l_k)p(x_k|l_{1:k}, x_{1:k-1})p(l_{1:k}|r_{1:k-1}) \\
 &= p(a_k|l_k)p(x_k|l_{1:k}, x_{1:k-1})p(l_k|l_{1:k-1})p(l_{1:k-1}|r_{1:k-1})
 \end{aligned}$$

$$\begin{aligned}
 \omega_k &\propto \frac{p(a_k|l_k)p(x_k|l_{1:k}, x_{1:k-1})p(l_k|l_{1:k-1})p(l_{1:k-1}|r_{1:k-1})}{q(l_k|l_{1:k-1}, r_{1:k})q(l_{1:k-1}|r_{1:k-1})} \\
 &= \omega_{k-1} \frac{p(a_k|l_k)p(x_k|l_{1:k}, x_{1:k-1})p(l_k|l_{1:k-1})}{q(l_k|l_{1:k-1}, r_{1:k})}
 \end{aligned}$$



Initialize



蒙特卡罗方法应用3:贝叶斯推理

能学院魏平编写。课程资料，请勿外传

- 计算视觉中的一个基本假设是，生物视觉和机器视觉计算输入图像最可能的解释，其贝叶斯表达

$$W^* = \arg \max \pi(W | I) = \arg \max p(I | W)p(W)$$

- 数据驱动的马尔可夫链蒙特卡罗(DDMCMC)



Zhuowen Tu and Song-Chun Zhu, 2002

蒙特卡罗方法应用4:学习和模型估计

在统计和机器学习中，需要计算能优化某些损失函数的参数，这些函数通常是高度非凸的，尤其是涉及隐变量的时候

吉布斯模型的学习

- 模型

$$p(\mathbf{I}; \Theta) = \frac{1}{Z} \exp\{-\langle \Theta, H(\mathbf{I}) \rangle\}$$

- 最大似然

$$\Theta^* = \arg \max \ell(\Theta), \text{ with } \ell(\Theta) = \sum_{i=1}^M \log p(\mathbf{I}_i^{\text{obs}}; \Theta)$$

- 似然求导

$$\int H(\mathbf{I}) p(\mathbf{I}; \Theta) d\mathbf{I} = \mathbf{h} = \frac{1}{M} \sum_{i=1}^M H(\mathbf{I}_i^{\text{obs}})$$

- 采样近似

$$\hat{\mathbf{h}}(t) = \frac{1}{M} \sum_{i=1}^M H(\mathbf{I}_i^{\text{syn}})$$

- 梯度更新

$$\frac{d\Theta}{dt} = \eta(\mathbf{h} - \hat{\mathbf{h}}(t))$$

蒙特卡罗方法与神经网络

清华大学人工智能学院魏平编写。课程资料，请勿外传

□ 受限玻尔兹曼机 (RBM)

- 模型
$$p(\mathbf{v}, \mathbf{h}; \Theta) = \frac{1}{Z} \exp(-E(\mathbf{v}, \mathbf{h}))$$

- 能量函数
$$E(\mathbf{v}, \mathbf{h}; \Theta) = -\mathbf{a}^T \mathbf{v} - \mathbf{b}^T \mathbf{h} - \mathbf{v}^T W \mathbf{h}$$

- 最大似然
$$\Theta^* = (W, \mathbf{a}, \mathbf{b})^* = \operatorname{argmax} \sum_{i=1}^n \log \int p(\mathbf{v}_i, \mathbf{h}; \Theta) d\mathbf{h}$$

□ 大规模目标分类Softmax

$$p(y_t | y_{<t}, x) = \frac{\exp \{ \mathbf{w}_t^\top \phi(y_{t-1}, z_t, c_t) + b_t \}}{\sum_{k: y_k \in V'} \exp \{ \mathbf{w}_k^\top \phi(y_{t-1}, z_t, c_t) + b_k \}}$$

机器翻译

