



中国科学院数学与系统科学研究院

Academy of Mathematics and Systems Science
Chinese Academy of Sciences

第十一章 大数据、机器学习与统计学

洪永淼

中国科学院数学与系统科学研究院

中国科学院大学经济与管理学院

Copyright © 2024 by Professor Hong Yongmiao, All rights reserved. Requests for permission should be mailed to: ymhong@amss.ac.cn

1. 版权归作者洪永淼教授所有；
2. 不得移除作者署名，否则将视为侵权；
3. 对于不遵守此声明或者其他违法使用本文内容者，作者依法保留追究权等。
4. 发现课件错误请联系作者 ymhong@amss.ac.cn

目 录

第一节 导言

第二节 实证研究与统计分析

第三节 大数据的主要特征

第四节 机器学习及其本质

第五节 大数据、机器学习与统计学的关系

- 随着互联网与移动互联网技术及其应用的快速发展，**大数据** (big data) 和用于大数据分析的**机器学习** (machine learning) 正在对统计科学产生深刻的影响。
- 大数据特征
 - ✓ 体量巨大，来源不一，种类繁多
 - ✓ 有结构化、半结构化、非结构化等各种形式
 - ✓ 大多数是实时或近乎实时生成和记录的数据



本章重要问题：

- 大数据是否改变了统计科学的理论基础？
 - ✓ 比如，随机抽样推断、充分性原则、数据归约、样本外预测、因果分析等统计方法，是否将会改变，甚至有些统计学的基本原理是否将不再适用？
- 大数据给统计建模与统计推断的理论与应用带来了哪些挑战与机遇？
- 作为大数据分析的重要工具，机器学习与统计建模的主要区别是什么？

本章重要问题 (Cont.):

- 机器学习与统计推断有什么联系与共同点?
- 统计学能否为机器学习提供有意义的理论基础与理论解释?
 - ✓ 众所周知, 基于大数据的机器学习常常能够提供较为精准的样本外预测, 但在大多数情况下, 它就像一个“黑箱 (black box)”, 很难甚至无法给予直观解释。
- 机器学习与统计学是否可以结合起来? 如果可以, 这种交叉融合对统计科学的未来发展将产生什么影响?

目 录

第一节 导言

第二节 实证研究与统计分析

第三节 大数据的主要特征

第四节 机器学习及其本质

第五节 大数据、机器学习与统计学的关系

统计推断的基本思想

- 假设所研究的系统是服从某一概率法则的随机过程，现实观测数据是从这个随机过程产生的，而这个随机过程称为**数据生成过程 (data generating process, DGP)**。




统计实证分析的主要目的

- 通过对观测数据进行统计建模，推断出 DGP 的概率法则或其重要特征，然后运用于各种实际应用中，如



解释经验典型特征事实



检验经济理论/经济假说



预测未来变化趋势



评估公共政策效应

参数建模 (parametric modeling) 方法

- 在统计建模与统计推断中，一般假设 DGP 的概率法则可由唯一的**数学概率模型**来刻画。
 - 模型通常将因变量与一些解释变量或预测变量联系起来。
- 同时，假设该数学模型的函数形式已知，但包含低维的未知参数。

统计推断的主要目的

用观测数据估计模型的未知参数值

将经济理论或经济假说转化为统计**参数假设**

进行参数**假设检验**，并对实证结果提供经济解释

统计实证研究中的常见做法

- 基于一个预设的**显著性水平**（如 5%）判断一个参数估计值或参数假设在统计学上是否显著，特别是使用检验统计量的 p -**值** 来判定参数估计值或参数假设的统计显著性。
 - 如果具有统计显著性，则相应的解释变量将视为一个重要决定因素，并留在统计模型中。
 - 如果一个具有统计显著性的解释变量没有被包含在统计模型中，则称该变量为遗漏变量，且模型误设。

- 常用的标准统计模型：
 - ✓ 经典线性回归模型
 - ✓ Probit 或 Logit 离散选择模型
 - ✓ 生存分析中的比例风险模型 (Cox, 1972)



Regression Models and Life-Tables

By D. R. Cox

Imperial College, London

[Read before the ROYAL STATISTICAL SOCIETY, at a meeting organized by the Research Section, on Wednesday, March 8th, 1972, Mr M. J. R. HEALY in the Chair]

SUMMARY

The analysis of censored failure times is considered. It is assumed that on each individual are available values of one or more explanatory variables. The hazard function (age-specific failure rate) is taken to be a function of the explanatory variables and unknown regression coefficients multiplied by an arbitrary and unknown function of time. A conditional likelihood is obtained, leading to inferences about the unknown regression coefficients. Some generalizations are outlined.

经济观测数据

- 经济观测数据一般指：在现实条件下所观测到的数据，这些数据不是在可控实验条件下产生的。
 - ✓ **非实验性**是经济学乃至社会科学的最显著特征。
 - ✓ 大多数实际观测数据的样本容量通常不太大。

观测数据以及相关的统计模型可能也存在各种缺陷，如

条件
异方
差与
相关

删
失
数
据

截
断
数
据

变
量
误
差

遗
漏
观
测
值

内
生
性

维
数
灾
难


弱
工
具
变
量

不可
观的
虚拟
事实

部
分
识
别

数据
操纵
与
数据
造假

- 统计分析直接或间接地基于至少**六个关键假设**：



目 录

第一节 导言


第二节 实证研究与统计分析

第三节 大数据的主要特征

第四节 机器学习及其本质

第五节 大数据、机器学习与统计学的关系


- 大数据的产生得益于信息技术的快速发展，尤其是互联网与移动互联网技术的广泛应用。



- 大数据的来源



- 金融市场、商品交易平台、扫描器与电子支付系统，记录了逐笔交易数据
- GPS 和北斗传感器记录气候环境数据与物理数据



- 各类企业特别是**互联网巨头**，以及政府网站提供有用的信息

- 截至 2019 年底，中国互联网与移动互联网用户人数超过 9 亿人，远远超过美国与欧盟网民人数的总和。
- **数据生产总值** (gross data product): 新的 GDP 概念，用于测度每个国家或地区的数据资源总量及其利用程度。

- 大数据的“4V”特征

海量性
(volume)


多样性
(variety)



高速性
(velocity)

真实性
(veracity)

海量性 (volume): 样本容量大, 变量个数多



海量性的双重含义

■ 高大数据 (tall big data):


大数据的样本容量很大且远大于解释变量或预测变量的维数

■ 胖大数据 (fat big data):

拥有一个高维的潜在解释变量或预测变量的集合，并且其维数超过样本容量

✓ 维数灾难

Curse Of Dimensionality



高速性 (velocity)

- 高速性指的是能够在**高频**甚至**实时**条件下记录或收集数据。这使得及时的数据分析与预测成为可能。
 - ✓ 构建高频宏观经济变量：居民消费指数 (CPI)、生产者物价指数 (PPI)

多样性 (variety): 大数据种类繁多、形式多样

- 传统结构化数字型数据
- 结构化新型数据
 - ✓ 函数数据、区间数据、符号数据
- 非结构化数据
 - ✓ 文本、图片、视频、音频等

真实性 (veracity)

- 与传统数据相比，大数据一般体量庞大。
- 但很多大数据**信息密度低，噪声大**，也可能存在遗漏数据和操纵数据，导致信息失真。
- 因此有必要进行数据清洗与处理。

- 由于大数据具有容量大、维度高与信息密度低等特点，统计学的**充分性原则**在大数据分析方面可发挥巨大作用，尤其在
 - ✓ 数据归约
 - ✓ 变量降维
- 因此迫切需要发展基于计算机算法的有效的**数据归约**方法

目 录

第一节 导言

第二节 实证研究与统计分析

第三节 大数据的主要特征

第四节 机器学习及其本质

第五节 大数据、机器学习与统计学的关系



“机器学习”这一术语由人工智能开拓者之一阿瑟·萨缪尔 (Arthur Samuel) 于1959年提出。



Arthur Samuel

- 机器学习三个主要类别
 - ✓ 监督学习 (supervised learning)
 - ✓ 无监督学习 (unsupervised learning)
 - ✓ 强化学习 (reinforcement learning)

- 机器学习就是从训练数据中寻找一个**有约束**的优化算法，使训练数据的损失函数加上**惩罚项最小化**，以达到精准样本外预测效果。
- 常见的**机器学习方法**包括
 - ✓ 决策树
 - ✓ 支持向量机
 - ✓ 随机森林
 - ✓ 人工神经网络
 - ✓ k 最近邻法
 - ✓ 深度学习

决策树

决策树学习将决策树作为预测方法，体现了从一些特征变量的观测值到目标变量的目标值的整个预测过程。





图 11.1：录取决策结果的决策树示意图


随机森林 (random forest)

基于原始观测数据，通过重复抽样产生一系列新的随机数据，**每个数据培植一棵决策树**，然后对产生的一系列决策树的预测值进行平均。




k 最近邻法 (k -nearest neighbor, k -NN)

根据一些特征变量的取值，选择 k 个取值最靠近某个预定值的特征变量观测值，然后将对应于这 k 个取值最邻近预定值的因变量观测值进行平均，作为对因变量的一个预测



支持向量机 (support vector machine, SVM)

支持向量机是一种用于分类和回归的监督学习方法。



人工神经网络 (artificial neural network, ANN)

是一个计算机算法系统，其部分灵感源自构成动物大脑的生物神经网络，通过考察训练数据的样例“学习”如何执行任务。





图 11.2 : 人工神经网络结构图

深度学习 (deep learning)

如果人工神经网络包含多个隐藏层，则称为深度学习方法。



目 录

第一节 导言

第二节 实证研究与统计分析

第三节 大数据的主要特征

第四节 机器学习及其本质

第五节 大数据、机器学习与统计学的关系

非结构化数据与文本回归分析

- 大数据特别是非结构化数据将带给我们更多有价值的信息，这些信息可用于发展新的统计方法与工具。
 - 社交媒体 (如微博和脸书) 数据通常以非结构化或半结构化形式呈现，但通过**爬虫**和**自然语言处理**等技术抓取信息，可用于构建新的解释变量或预测变量，如

✓ 消费者幸福感指数	✓ 经济政策变化指数
✓ 投资者情绪指数	✓ 社会舆情指数
✓ 经济政策不确定性指数	✓

- 这些从文本数据构建的重要变量包含传统数据所没有的信息，可通过**统计回归模型**等方法，分析与测度它们对社会经济金融市场的影响，这就是所谓的**文本回归** (textual regression) 分析。

Textual Analysis




- 此外，还可以通过大数据与人工智能方法，构造高频宏观经济时间序列指数
 - ✓ 如 CPI 和 PPI 的每日时间序列数据
- 这将有助于我们及时预测宏观经济的变化趋势，包括**实时预测** (nowcasting)。



- 目前，绝大部分宏观经济指标最高频数据是月度数据
 - ✓ GDP 还没有月度数据
- 大数据的出现和人工智能技术的使用可以显著提高宏观经济数据的**测度频率**。

抽样推断原则

- 大数据并不意味着可以获取 DGP 的总体分布的完全信息。
- 推论统计学的基本思想：从随机样本推断总体分布特征，而所推断出来的总体分布特征，也适合于刻画从同一总体分布产生的其他随机样本。



- 假设某一参数统计模型是**正确设定**，则当样本容量非常大时，不必担心参数估计量的**抽样变异性** (sampling variability)，即参数估计不确定性将可以忽略不计。
- 但是通过随机样本推断总体分布特征的统计思想仍未改变，取而代之的很可能是**模型选择不确定性**
 - ✓ 存在大量解释变量
 - ✓ 解释变量具有多重共线性
 - ✓ DGP 具有异质性或时变性
 - ✓ 模型误设

- 与统计学一样，机器学习也假设 **DGP 是一个随机过程**，而且其结构或概率法则未知。
- 机器学习的主要目的：基于对训练数据的“学习”经验，预测未知样本的行为或表现。
- 机器学习就是从训练数据中挖掘出可以泛化到未知数据的系统特征，并根据这些共同系统特征进行预测。
- 机器学习也可视为遵从**抽样推断总体分布性质**的统计思想。

统计显著性与经济显著性

- 由于大数据的样本容量大，我们可以探索大数据中可能存在的**非线性**、**时变性**、**异质性**等复杂结构。
- 另一方面，样本容量大也可能给统计建模与统计推断的习惯做法带来挑战。
 - 比如，对于样本容量不是很大的传统数据，如果一个解释变量的参数估计量的 p -值根据预设**显著性水平**（一般为 5%）具有统计显著性，那么通常认为该解释变量是**重要变量**。

◆ 问题

现在假设有一个样本容量为 100 万的大数据，恰好达到 5% 显著性水平的参数估计量意味着什么？

- 显然，对于如此大的样本容量，该参数值可能会非常接近（但不等于）零，但具有**统计显著性并不意味着具有现实重要性或经济重要性**。
- 因此，大数据的大样本容量使得传统的统计显著性检验变得不再适合。

◆ 问题

当样本容量达到 100 万这么大时，如何衡量解释变量的经济重要性呢？

- 机器学习领域已提出各种判断**特征重要性** (feature importance) 的方法，其中所谓特征其实就是解释变量。

模型多样性与模型不确定性

- **模型多样性** (model multiplicity): 基于某一**统计准则** (如均方误), 不同的统计模型有可能呈现相似甚至相同的统计表现。
- 一般而言, 如果数据杂糅或者不同状态下存在不同经济行为, 那么**模型平均** (model averaging) 或模型组合可能是最佳预测方法。

- **模型不确定性** (model uncertainty): 解释变量多, 近似多重共线性; 基于同一统计准则, 对数据的“微扰”可能会导致最优统计模型的显著改变。
- 在机器学习领域, 为了克服模型不确定性, Breiman (2004) 提出**随机森林**方法。

随机森林: 通过计算机重复抽取产生一系列相关性不太强的随机样本, 对每个样本训练一棵决策树, 然后对所有决策树预测取平均以获取稳健预测。

充分性原则、数据归约与维数约简

- 如果大数据包含高维潜在解释变量的信息，关于 DGP 的横截面信息就非常丰富。
- 当解释变量的数目多于样本容量时，需要发展新的统计降维方法以选择重要解释变量，这其实是一种**数据归约** (data reduction) 方法。
 - ✓ 数据归约本质上是统计学**充分性原则**的一种方法。

- 创新分析大数据的数据归约方法：**变量降维** (dimension reduction)，特别是在胖大数据条件下的变量选择。




- **LASSO** (Tibshirani, 1996): 可以在一个高维线性回归模型框架中挑选出重要解释变量并排除众多不相关的协变量。

LASSO 基本思想

- 假设线性回归模型

$$Y_i = \sum_{j=1}^p \beta_j X_{ji} + \varepsilon_i, \quad i = 1, 2, \dots, n$$

- 稀疏性** (sparsity) 假设：所有潜在解释变量中只有少数未知变量的系数不为零。
- 目标函数**: $\min \sum_{i=1}^n (Y_i - \sum_{j=1}^p \beta_j X_{ji})^2 + \lambda \sum_{j=1}^p |\beta_j|$



机器学习与非参数建模

◆ 问题


机器学习不用参数统计模型，而是直接基于数据构建算法。为什么机器学习方法在大数据条件下能够得到比较精准的样本外预测？

- 机器学习算法类似于统计学的非参数分析方法。具有很强烈的**非参数方法**的特征，并且使用基于**测试数据**的泛化准则。

- 面对大数据中高维的潜在解释变量，机器学习可以通过合适算法快速“穷尽”所有合适的解释变量子集，为最佳预测挑选出一个低维的重要解释变量集合。
 - 机器学习之所以能够实现有效降维与精准样本外预测，主要是因为它通过一个惩罚项对数据拟合进行规制 (regularization)，**避免了过度拟合** (overfitting)。
- 机器学习与非参数方法一样，并不依赖某一个特定的统计模型，因此机器学习发现的证据将比较接近数据证据，从而避免参数统计模型的缺点。

相关性与因果关系

- 曾经有一种观点，认为大数据分析只需要相关性，不需要因果关系。
- 然而，很多情况下，经济因果关系在**高频或实时**条件下无法充分显示，所以不需要因果关系的论断是不对的，至少不适用于经济学。



◆ 问题

什么是因果关系？

- 假设所有其他变量 Z 不变，只让一个变量（如政策变量 X ）变化，观察结果（因变量 Y ）是否发生变化。如果有，则称存在从 X 到 Y 的因果关系。
- **实验科学：**实验组与控制组满足“同等条件”假设，进行可控实验，进而识别因果关系。
- 然而，在计量经济学中，当评估政策效应时，由于经济系统的非实验性特点，往往无法进行控制实验。

- 在过去 20 年，计量经济学诞生了一门新兴学科，即**政策评估计量经济学** (econometrics of program evaluation)，研究**非实验条件**下经济因果效应的识别与测量。

◆ 问题

如何测度政策效应？

- 统计学和计量经济学使用虚拟事实 (counterfactuals) 估计方法。

➤ **基本思想**：在同等条件下，比较实施了该政策的观测结果 Y 与假设没有实施该政策的虚拟事实 Y^* 。

$$\text{政策效应} = Y - Y^*$$

- 由于虚拟情况不会真正发生，故需要对虚拟事实进行估计，这实质上是一种预测，可以借助一个统计模型或**机器学习**精准预测。

新型数据建模

新型数据

函数数据



一天内温度的变化



开盘到收盘的股票价格变化



一定时期内交通流量的变化

区间数据



病人每天的最高与最低血压



每天的最高气温与最低气温



每天股票的最高与最低价格

- 很多情况下，将新型数据转换为点数据，通常伴随着信息损失。因此，对这些新型数据**直接进行建模**比先将它们转化为传统点数据再建模更有价值。
- 新型数据需要新的统计模型与统计方法。统计学和计量经济学已产生一些**原创性成果**，如
 - ✓ **函数数据分析** (functional data analysis)
 - ✓ **区间数据建模** (interval-valued data modeling)



中国科学院数学与系统科学研究院

Academy of Mathematics and Systems Science

Chinese Academy of Sciences

Thank You !